

05


함수 근사법

2. 경사하강법




경사하강법

스칼라와 벡터



스칼라(Scalar)와 벡터(Vector)



$$f(x) = x^2$$


$$f(x)' = 2x$$

- 스칼라 : 크기만 있고 방향이 없는 데이터
ex) 몸무게, 수학점수, 키
- 벡터 : 크기와 방향을 모두 가지고 있는 데이터
ex) 자기력, 속도, 가속도
- 스칼라를 미분 또는 편미분하면 벡터로 변하며 방향성을 가진다




경사하강법

그래디언트



그래디언트(Gradient)



함 수

$$z = f(x, y) = 2x^2 + 2y^2$$

그래디언트


$$\begin{aligned}\nabla f &= \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right) \\ &= (4x, 4y)\end{aligned}$$

- 그래디언트는 공간의 기울기를 의미
- 그래디언트는 모든 변수에 대한 편미분을 각각 구하고 행렬의 형태로 구성
- 점(2)에서 $(x, y) = (1, 1)$ 이라면 그래디언트 값은 $(4, 4)$ 가 된다. x 와 y 모두 값이 늘어나는 방향으로 4의 크기를 가지고 값이 변화한다는 것




경사하강법

기본개념



경사하강법(Gradient Decent)



함 수

그래디언트

변수 증분

- 경사하강법 : 반복적인 계산을 통해 미분 가능한 함수의 가장 작은 값 (극소점 : local minimum) 을 찾아내는 최적화 알고리즘
- 경사상승법 : 이와 반대로 함수의 가장 큰 값 (극대점 : local maximum) 을 찾아내는 최적화 알고리즘

$$z = f(x, y) = 2x^2 + 2y^2$$


$$\nabla f = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$$

$$\Delta(x, y) = -\frac{1}{2} \propto \nabla f$$



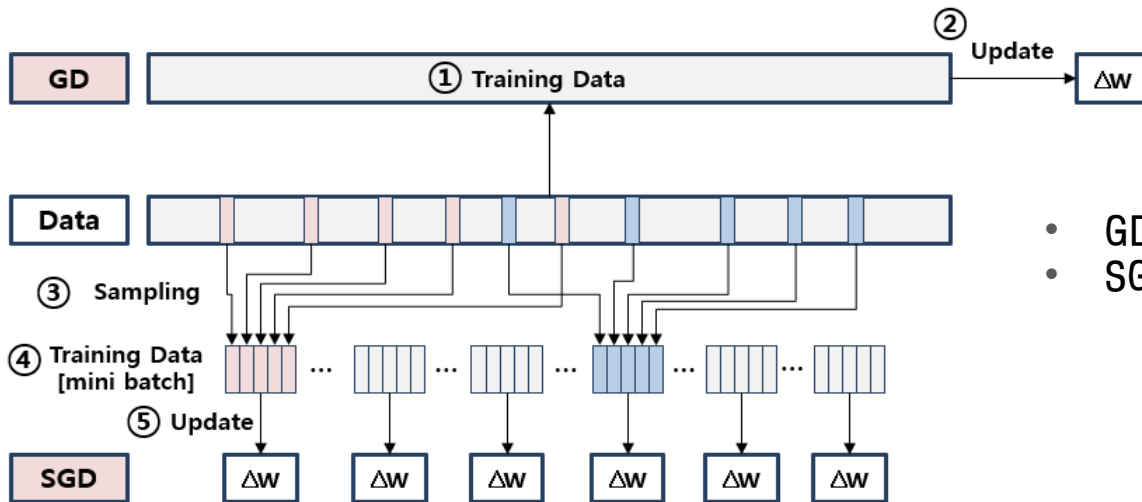
경사하강법

확률적 경사하강법



확률적 경사하강법(SGD: Stochastic Gradient Decent)


- 전체 데이터가 아닌 일부 데이터만 학습하고 좀 더 빨리 값을 수정해 가는 알고리즘



- GD : 전체 데이터
- SGD : 일부 데이터



경사하강법 표기법



강화학습에서 GD와 SGD 표기법

- 데이비드 실버(David Silver) 교수님이 작성한 강의교재에 기초한 표기법 사용

일반수식 : 편미분

$$\nabla f(x, y) = \left(\frac{\partial f}{\partial x}, \frac{\partial f}{\partial y} \right)$$

강화학습 : 편미분

$$\nabla_w J(w) = \left(\frac{\partial J(w)}{\partial w_1}, \dots, \frac{\partial J(w)}{\partial w_n} \right)$$

일반수식 : 경사하강법

$$\Delta(x, y) = -\frac{1}{2} \nabla f$$

강화학습 : 경사하강법

$$\Delta w = -\frac{1}{2} \nabla_w J(w)$$

